


ИЗВЕШТАЈ

Knowledge Distillation у Computer Vision-у – Teacher-Student метод

Ведран Митић 2123

Увод

Идеја дистилације знања је прешла не толико временски колико истраживачки пут од концепта у коме је виђена као метод компресије модела, до њене „моћи“ регуларизације. Иако постоје пионирски радови на ову тему, први пут се назив ове методе формализује 2015. године у раду [1] и до данас задржава свој основни концепт – постојање два модела, учитеља и студента.



Слика 1. Генерализовани приказ методе ДЗ

Учитељ је велики модел, углавном неки од *state-of-the-art* модела који је истрениран на великим скуповима података, а студент мањи модел који има за циљ да опонаша знање учитеља уз сличне резултате. Учитељ, често у литератури називан и гломазни, *cumbersome* модел, се најпре тренира како би се извукле структуре и репрезентације података (деталји и сличности између класа). Научено знање се затим дестилује у студента који на тај начин врло често има и ширу слику о ономе што учи у односу на ону коју је имао учитељ при учењу. Приказ методе је дат на Слика 1.

Сама метода се састоји од три кључне компоненте:

1. Знања (према извору одакле долази):


- *Response-based* знање – знање изведено из последњег (излазног) слоја модела;
- *Feature-based* знање – знање извучено из средњих слојева (скривених) слојева;
- *Relation-based* знање – знање које се заснива на међусобним односима и структурама самих података.

2. Алгоритма дестилације (према начину учења, Слика 2):

- *Offline* дестилација – посебан тренинг учитеља → екстракција знања → тренинг студента;
- *Online* дестилација – истовремено тренирање учитеља и студента;
- *Self-distillation* – исти модел има улогу учитеља и студента.

3. Учитељ-студент архитектуре:

Иако у литератури не постоји устаљена подела учитељ-студент архитектуре, интуитивно се може закључити да се за учитеља одабира комплекснији *state-of-the-art* модел, а за студента модел са смањеним капацитетом архитектуре [2]. Ова таксономија се може даље проширивати, а са преласком на трансформер архитектуру и допунити значајним новинама попут *DeiT*-а [3].




Слика 2. "Различити типови дестилације. Црвена боја "Pre-trained" означава да су мреже истрениране пре дестилације, а жута боја "To be trained" означава да мреже уче током дестилације." [2]

Практични део рада обрађује *offline Response-based* дестилацију.

Response-based ДЗ – Џ. Хинтон

Термин „дестилације“ знања се први пут се јавља у раду [1], као назив за процес преношења знања са већ истренираног, гломазног, на мали модел. Главни изазов који је до тада постојао у овој области јесте како заправо променити форму модела, а да се задржи исто знање. Такође, циљ је и надвисити резултате које би поставио мали модел истрениран по истом принципу и скупу података као велики модел. Решење које се представило у виду ДЗ, заправо је једноставно преношење „меких“ циљева (*soft targets*) студенту, на основу којих би он извршавао додатан тренинг. Меки циљеви нису ништа друго до вектор вероватноћа предвиђених класа на излазу учитеља које служе као *target* лабеле за мали модел. У пракси, то би значило да студент нема информацију само о „тврдим“ циљевима (*hard targets*), што су већ познате лабеле припадности класа (0 или 1), већ и информацију о

томе како учитељ види сам податак (нпр. слику). Па тако, ако је учитељ видео слику пса са вероватноћом од 30% да је то вук, а 5% да је то мачка, студент ће успети да научи не само да је на слици пас, већ и да пас садржи одређене сличности са вуком. За исти пример, уколико би учитељ видео слику са вероватноћом 0.5% да је то аутомобил, студент би научио и да је пас много сличнији мачки него аутомобилу. На овај начин је дистинкција између класа разумљивија и богатија од пуког форсирања оптимизације ка *hard* лавелама. Ове вероватноће се прилагођавају мењањем вредности температуре T у *softmax* слоју тако што се са повећањем T униформише њихова дистрибуција. [1] указује и на то да како се ентропија вероватноћа повећава, тако оне пружају већи извор информација по узорку и много мање варијансе у градијенту, па је за тренинг потребан мањи скуп података од оригиналног и већа стопа учења, чиме се тренинг знатно убрзава.



Слика 3. Графички приказ архитектуре ДЗ

Када је број класа веома велики, [1] предлаже да гломазног учитеља чини ансамбл модела који је се састоји од једног великог, моћног модела који се обучава на свим подацима – „Генералиста“ и више модела „Специјалиста“. Тренинг се најпре обавља над Генералистом чије се грешке посматрају и од којих се праве кластери класа које су му биле проблематичне за класификовање. Затим се креирају Специјалисти (такође велики модели иницијализовани тежинама Генералисте) који се обучавају само на проблематичним класама, тако да је сваки Специјалиста задужан за један кластер, чиме се уче „фине“ разлике које је Генералиста пропустио. На тај начин се стварају *Fine-grained* класе, типови подкласа одређених класа, односно подкласе које се међусобно разликују по неким скривеним детаљима. Нпр. модели аутомобила унутар класе аутомобила. За смањење оверфитинга код Специјалиста, половину података при тренингу чине узорци из специјалних подкласа, а половина је насумично узрокована из остатка оригиналног скупа

података. За смањење пристрасности (*bias*), може се повећати логит „*dustbin*“ класе (класа која представља комбинацију свих свих класа којима се Специјалиста не бави) за логаритам пропорције за коју је класа Специјалисте „преузрокована“ (*oversampled*), колико пута ћешће се специјалне класе појављују у тренинг сету специјалисте у поређењу са стварном учесталости у оригиналном скупу података) [1].

Soft target који се прослеђује студенту се представља вектором заједничких дистрибуција вероватноћа Генералисте и активних Специјалиста – q , који се добија минимизовањем збира њихових KL дивергенција:

$$KL(p^g, q) + \sum_{m \in A_k} KL(p^m, q) \quad (1)$$

где p^g представља дистрибуцију вероватноћа Генералисте, p^m дистрибуцију вероватноћа свих специјалних класа из m , плус *dustbin* класа.

Коначно, учење студента се постиже минимизацијом крајње функције губитка која представља пондерисану суму знања из стварних лабела и знања из учитеља („скривено“ знање, „*Dark Knowledge*“):

$$L_{total} = (1 - \alpha)L_{CE}(y, \sigma(z_s)) + \alpha T^2 L_{KL}(q, \sigma(\frac{z_s}{T})) \quad (2)$$

где је α хиперпараметар који одређује тежину ослањања на сваку од функција губитака, L_{CE} функција губитака класификације (унакрсна ентропија) између тачних лабела y и излаза софтмакс функције логита студента $\sigma(z_s)$, L_{KL} функција губитка дестилације (Кулбак-Лајблер дивергенција) између учитеља q ($\min((1))$) и софтмакс функције логита студента $\sigma(\frac{z_s}{T})$ при $T > 1$. Дестилациони губитак се множи фактором T^2 из разлога што се са повећањем температуре, магнитуда градијанта смањује за $\frac{1}{T^2}$. Приказ методе, графички је осликан на Слика 3.

Главни проблем Хинтонове ДЗ је био „нестајући“ (*vanishing*) градијент при дубљој архитектури студента у односу на учитеља. Међутим, ово је убрзо превазиђено новим методама и архитектурама мрежа као што су *feature-based* ДЗ или „прескачуће“ (*ResNet*) конекције.

ПРАКТИЧНИ ДЕО

Практични део је спроведен коришћењем Google Colab-a.

Скуп података

Скуп података је *EPT100* који се састоји од 100 класа микроскопских снимака инсеката, а подељен је на тренинг (8538 слика), валидациони (3368 слика) и тест скуп (5152 слика). У валидационом скупу недостају слике за 4 класе (140, 159, 179 и 181), па треба обратити посебну пажњу на правилно постављање кода како би се узорци тих класа правилно мапирани при тренингу. Све слике су димензија 512x512.

Како се користи Colab, најбоље је најпре повезати се на *Google Drive* на ком је претходно постављен *.ZIP* фајл датасета (*Dataset.zip*), а онда помоћу кода тај фајл пребацили из драјва у локални колабов filesystem и ту га распаковати директно. Ово је најбржи начин, јер би иначе касније читање слика са драјва било преспоро. Након распакивања, а пре покретања наредних ћелија, ручно обрисати из *val_512* фолдера претходно набројане празне фолдере.

Избор модела

За модел учитеља је изабран *EfficientNet-B2* како би се резултати могли упоредити са већ постојећим за овај скуп података.

За студенте су изабрана три различита модела:

1. *EfficientNet-B0* – мања верзија учитељ модела. Очекивано је да овај модел постигне најбоље резултате у односу на остале због компатибилности са учитељем.
2. *TinyCustom CNN* – ручно направљен модел који се састоји од укупно 9 конволуција, прављен по узору на *MobileNet*. Архитектура приказана на Слика 4below.
3. *MobileNet V3* – најпознатији модел за *Edge* уређаје.

Разлог зашто су коришћени модели прилагодљиви за *Edge* уређаје је зато што осим покушаја да се докаже успешност технике ДЗ је и покушај да се докаже њена директна применљивост у области компресије знања на мање уређаје. Различите архитектуре модела су изабране како би се видела успешност технике када је студент исте и другачије архитектуре од модела учитеља.

Хиперпараметри

Учитељ је подешен тако да у сваком тренутку прима слике у оригиналној резолуцији 512x512 – и током тренинга и током ДЗ. Студенти примају слике у резолуцији 224x224, првенствено због мањег капацитета који поседују, а и због симулације *Edge* уређаја чија би камера вероватно била слабијег квалитета. Слике се у 224x224 добијају билинеарном интерполацијом. Величине бечева су 16.

Стопа учења је 10^{-4} , сем код TinyCustom CNN-а где је постављена на 10^{-3} јер је модел прављен ручно. Weight decay је 10^{-4} .

Број епоха је иницијално подешен на 30 јер је то неко просечно време за које се Colab кредити неће истрошити. Овај параметар се свакако повећава са достизањем сваког *checkpointa*.

Параметри дестилације знања су $\alpha = 0.7$ и $T = 3$ ($T = 10$).

Подешавања

Учитељ модел користи претрениране тежине на *ImageNet-1K* и *fine-tune*-ован је одмрзавањем класификатора и последњег слоја Efficient Net-a. Ово је урађено ради уштеде времена за тренирање учитеља који је највећи модел. Сви студент модели су тренирани од нуле.


Дестилација знања је подешена тако да хиперпараметар алфа стоји уз губитак ДЗ, што значи да тај губитак чини 70% укупног губитка. Функција губитка ДЗ је КЛ дивергенција, а са хард лабелама унакрсна ентропија.

Мере евалуације модела су Топ-1 и Топ-5 тачности, мада се Топ-5 може занемарити.

Early Stopping је за учитеља 7, а за студенте 15. Провера се врши у односу на вредност грешке уместо у односу на тачност због могућности оверфитинга. Грешка је побољшана уколико валидациона грешка опадне за више од 0.001 (хиперпараметар *min_delta*).

Оптимизатор је *AdamW*, *scheduler* стопе учења је *CosineAnnealing*.

У тренинг скупу је примењена следећа аугментација: *Random Horizontal Flip*, *Random Vertical Flip*, *Color Jitter*, *Random Rotation*. Подаци су нормализовани по *ImageNet* стандарду.



Слика 4. Архитектура TinyCustom CNN-a

Резултати

	T = 3 и $\alpha = 0.7$							T = 10 и $\alpha = 0.7$									
	Тренинг и валидација					Тест		Тренинг и валидација					Тест				
Модел	Топ-1	Топ-5	Best Val Loss	Број епоха	Early stopping	Топ-1	Топ-5	Топ-1	Топ-5	Best Val Loss	Број епоха	Early stopping	Топ-1	Топ-5	Бр. параметара (милиона)	Величина (МБ)	
Teacher (EfficientNet-B2)	98.58%	100%	0.044	30	5	98.43%	99.92%	x	x	x	x	x	x	x	7.91	30.3	
Student (EfficientNet-B0) HL	92.06%	99.56%	0.2769	50	15	91.01%	99.53%	x	x	x	x	x	x	x	4.18	16.1	
Student (EfficientNet-B0) KD	94.11%	99.20%	0.6186	113	15	93.21%	98.97%	94.37%	99.23%	0.4129	119	15	93.32%	98.89%	4.18	16.1	
Student (TinyCustomNet) HL	90.11%	99.23%	0.3619	51	15	89.09%	99.34%	x	x	x	x	x	x	x	0.09	0.4	
Student (TinyCustomNet) KD	90.58%	98.93%	0.8804	74	15	88.94%	98.76%	93.22%	99.32%	0.6202	112	15	91.38%	99.36%	0.09	0.4	
MobileNet V3 HL	89.31%	99.44%	0.3571	106	15	87.62%	99.30%	x	x	x	x	x	x	x	1.63	6.3	
MobileNet V3 KD	89.51%	98.90%	0.7645	105	15	88.35%	98.89%	89.48%	98.82%	0.5929	120	15	88.16%	98.72%	1.63	6.3	


Табела 1. Тренинг, валидациони и тест резултати модела
Италик и Болдирано – најбољи резултат у оквиру свих модела
Болдирано – најбољи резултат у оквиру подгрупе модела студента

Тренинг


Процес дестилације знања није успео да погура успешност мањих модела до високих 98% тачности, али је свакако успео у једном – да надмаши успешност модела када је трениран само на хард лабелама. Највидљивија разлика је код *EfficientNet-B0* од **+2.05%** тачности за $T = 3$. Ово је и било очекивано с обзиром на сличност архитектуре са учитељем.

TinyCustom Net и *MobileNet V3* су повећали тачност за **+0.47%** и **+0.20%** респективно. Још се већи помак види са повећањем температуре на $T = 10$: **+2.31%** код *EfficientNet-B0*, **+3.11%** код *TinyCustom Net* и **+0.17%** код *MobileNet V3*. Повећање температуре је дозволило и дуже тренирање студентата што се види у повећању броја епоха. Коначно, повећање температуре је значајно смањило грешку валидације код свих модела. Како температура утиче на предикције може се видети на Слика 7.

Модел тренирани само на хард лабелама, не само што имају најгоре резултате тачности, већ и знатно мање простора (епоха) за тренинг (учење). Изузетак је *MobileNet V3* који је био „најотпорнији“ на дестилацију знања. Такође, овако тренирани модели имају мању грешку валидације, што је узрок саме функције губитака. Код модела са ДЗ, укупни губитак садржи и КЛ дивергенцију која се множи са T^2 (квадратом температуре). Због тога је губитак ДЗ нумерички увек већи од обичне унакрсне ентропије коју користе модели на хард лабелама.



Слика 5. График промене грешке на валидационим подацима кроз епохе



Слика 6. График промене тачности над валидационим подацима кроз епохе

Инференција

При температури $T = 3$, дистилација знања је допринела код *EfficientNet-B0* (+2.20%) и *MobileNet V3* (+0.73%), док је занимљиво код *TinyCustom Net* тачност опала за -0.16%. Са повећањем температуре на $T = 10$, тачност за *TinyCustom Net* се овога пута повећала за +2.44% у односу на дистилацију са температуром $T = 3$ и +2.29% у односу на тренинг са хард лабелама, за *MobileNet V3* се тачност одржала вишом од почетне, али је нижа него са $T = 3$, док је код *EfficientNet-B0* успела да надмаши претходне резултате са 93.32% тачности. Број погрешних класификација на тест сету дат је у Табела 2.

Модел	Грешке	Укупно
Teacher (EfficientNet-B2)	81	5152
Student (EfficientNet-B0) HL	463	5152
Student (EfficientNet-B0) KD $T = 3$	350	5152
Student (EfficientNet-B0) KD $T = 10$	344	5152
Student (TinyCustomNet) HL	562	5152
Student (TinyCustomNet) KD $T = 3$	570	5152
Student (TinyCustomNet) KD $T = 10$	444	5152
MobileNetV3 HL	638	5152
MobileNetV3 KD $T = 3$	600	5152
MobileNetV3 KD $T = 10$	610	5152


Табела 2. Број погрешних класификација на тест сету

Треба узети у обзир да међу овим грешкама постоји 25 слика које ни један модел није успео да погоди, што је 0,49% тест података. Са $T = 10$ тај број слика је 22. Ове слике вероватно представљају објективни шум у виду грешке у лабелирању или екстремно лоших снимака. Табела 3 показује да број заједничких грешака са учитељем остаје стабилан у опсегу од 43 до 52 слике за све дестиловане моделе, што указује на то да студенти конзистентно наслеђују тешко решиве узорке из учитељевог сета погрешних класификација.

Модел	Teacher EfficientNet- B2	EfficientNet- B0 HL	EfficientNet- B0 KD	EfficientNet-B0 KD $T = 10$	TinyCustom Net HL	TinyCustom Net KD	TinyCustom Net KD $T = 10$	MobileNetV 3 HL	MobileNetV 3 KD	MobileNetV3 KD $T = 10$
Teacher EfficientNet- B2	81									
EfficientNet- B0 HL	39	463								
EfficientNet- B0 KD	46	243	350							
EfficientNet- B0 KD $T =$ 10	43	227	250	344						
TinyCustomN et HL	53	259	216	218	562					
TinyCustomN et KD	50	223	205	204	347	570				
TinyCustomN et KD $T = 10$	51	204	195	189	304	377	444			
MobileNetV3 HL	51	310	256	245	327	304	251	638		
MobileNetV3 KD	52	290	241	234	323	314	274	375	600	
MobileNetV3 KD $T = 10$	50	286	253	239	310	296	254	384	357	

Табела 3. Заједничке грешке свих модела (Број слика које су оба модела лоше класификовала)

Издвојивши неколико погрешно класификованих (из претходно споменутог скупа од 22 слике) и тачно класификованих узорака (из скупа 3791 слике коју су сви погодили), посматрањем додељене вероватноће за предиктовану погрешну класу у табели 4 и додељену вероватноћу за предиктовану тачну класу табели 5, може се приметити да дестиловани модели углавном предиктују са мањом сигурношћу од оних који су тренирани само на хард лабелама, што је доказ регуларизационе моћи ове методе. Док модел трениран на хард лабелама показује екстремну и ригидну самоувереност при погрешној класификацији (често преко 90%), модели са ДЗ показују знатно већу уздржаност. Ово је очекивана појава јер КЛ дивергенција учи студента да копира омекшане вероватноће учитеља (Слика 7), активно га кажњавајући када екстремно фаворизује само једну класу. Са повећањем температуре на $T = 10$, услед боље генерализације и раста укупне тачности модела, повећава се и сигурност којом студенти погађају тачну класу (Табела 5), док се истовремено задржава заштита од превелике самоуверености при грешкама у односу на моделе трениране само на хард лабелама.



Слика 7. Утицај промене температуре на излазе учитеља


Модел	Тачна класа = 119 Предиктована класа	Додељена вероватноћа	Тачна класа = 123 Предиктована класа	Додељена вероватноћа	Тачна класа = 123 Предиктована класа	Додељена вероватноћа
Teacher (EfficientNet-B2)	137	68.7%	154	97.3%	124	87.3%
(EfficientNet-B0) HL	137	99.8%	154	92.2%	124	84.2%
(EfficientNet-B0) KD T = 3	137	59.4%	154	78.5%	124	67.0%
(EfficientNet-B0) KD T = 10	137	83.5%	154	79.1%	124	58.8%
(TinyCustomNet) HL	115	57.0%	154	95.4%	124	38.2%
(TinyCustomNet) KD T = 3	137	42.5%	154	42.7%	124	21.5%
(TinyCustomNet) KD T = 10	137	30.2%	154	68.3%	124	27.9%
MobileNetV3 HL	137	99.8%	154	79.7%	124	89.8%
MobileNetV3 KD T = 3	137	70.4%	154	36.9%	124	17.2%
MobileNetV3 KD T = 10	137	80.3%	124	31.2%	124	81.0%

Табела 4. Примери погрешно класификованих узорака

Модел	Тачна класа = 108 Додељена вероватноћа	Тачна класа = 119 Додељена вероватноћа	Тачна класа = 107 Додељена вероватноћа	Тачна класа = 110 Додељена вероватноћа	Тачна класа = 138 Додељена вероватноћа
Teacher (EfficientNet-B2)	100.00%	100.00%	99.97%	99.83%	99.79%
(EfficientNet-B0) HL	97.96%	99.08%	68.74%	97.50%	99.99%
(EfficientNet-B0) KD T = 3	47.21%	64.36%	39.46%	67.95%	71.13%
(EfficientNet-B0) KD T = 10	75.00%	86.53%	85.37%	82.29%	84.23%
(TinyCustomNet) HL	91.13%	98.51%	93.60%	94.38%	97.11%
(TinyCustomNet) KD T = 3	52.69%	73.48%	64.01%	66.62%	51.88%
(TinyCustomNet) KD T = 10	86.84%	83.10%	92.96%	74.54%	66.73%
MobileNetV3 HL	98.77%	99.99%	99.30%	99.89%	98.86%
MobileNetV3 KD T = 3	37.46%	77.37%	82.75%	66.09%	71.07%
MobileNetV3 KD T = 10	69.99%	90.66%	46.70%	81.16%	91.68%

Табела 5. Примери тачно класификованих узорака

Користећи *Grad-CAM* визуелизацију за увид у начин на који модели виде слику пре класификације добија се резултат на слици Слика 8. Јасно је да учитељ готово перфектно издваја инсекта са слике с обзиром на његову комплексност и резолуцију у којој слику види. Са друге стране, основни модели тренирани без дестилације (*EfficientNet-B0* и *MobileNetV3*) фокусирају се доминантно на главу и предњи део инсекта, при чему показују расут фокус који захвата и небитну позадину изнад и испод објекта. Са повећањем температуре на $T = 10$, пажња дестилованих модела постаје знатно уздржанија према позадини и почиње правилно да прати контуре самог инсекта. Овај тренд је посебно уочљив код *TinyCustom Net* модела, који је кроз дестилацију успео да своју пажњу успешно преусмери и дистрибуира дуж читавог тела инсекта, блиско апроксимирајући мапу пажње коју поседује учитељ.




Слика 8. *Grad-CAM* визуелизација

Једна од најважнијих карактеристика за *Edge* моделе је брзина инференције, дата у Табела 6. Логично, брзина је обрнуто сразмерна величини модела, односно броју параметара. За тренутно истрениране моделе, најоптималнији одабир би био *TinyCustom Net Knowledge*

Distillation са $T = 10$. Овај модел је успео да превазиђе 90% тачности, а да је при том **8.16** пута бржи (8.31 пута на *CPU*) од истог *Efficient Net-B0*, а **12.22** пута бржи (93.68 пута на *CPU*) од учитеља.

Модел	Топ-1	GPU кашњење (ms)	CPU кашњење (ms)	Параметри (M)
Teacher (EfficientNet-B2)	98.427795%	12.381394	374.145792	7.841894
(EfficientNet-B0) HL	91.013199%	8.308280	36.116261	4.135648
(EfficientNet-B0) KD T = 3	93.206522%	11.038508	37.871001	4.135648
(EfficientNet-B0) KD T = 10	93.322981%	8.266258	33.190138	4.135648
(TinyCustomNet) HL	89.091615%	1.016233	3.878694	0.091044
(TinyCustomNet) KD T = 3	88.936335%	1.134076	3.823178	0.091044
(TinyCustomNet) KD T = 10	91.381988%	1.013339	3.993804	0.091044
MobileNetV3 HL	87.616460%	5.299416	12.963986	1.620356
MobileNetV3 KD T = 3	88.354037%	7.082109	14.010763	1.620356
MobileNetV3 KD T = 10	88.159938%	7.149558	9.435546	1.620356

Табела 6. Време инференције модела



Слика 9. График односа времена инференције и тачности модела

Закључак

За дати скуп података, метода *response-based* дестилације знања је потврдила теорију постигавши помак у тачности свих модела студената и учинивши их генерализованијим у односу на на верзије трениране искључиво на хард лабелама. За ближе достизање перформанси учитеља *Efficient-Net B2*, у даљем раду би требало покушати са коришћењем претренираних тежина и код модела студената, на начин на који је то учињено код њега. Када је у питању *TinyCustom Net*, најпре се може додатно експериментисати са хиперпараметрима како би се добио бољи базни модел, па поновити поступак дестилације. Такође, финијим подешавањем параметара температуре и алфа се може пронаћи најоптималне решење за дати скуп података. Поред тога, било би ефикасније направити већи капацитивни јаз између модела учитеља и студената, односно изабрати или много већи модел од *Efficient-Net B2* или много мањи од *Efficient-Net B0* (учитељ је овде већи само 1.9 пута). У овом раду је то мало компензовано тиме што учитељ види слике у дупло већој резолуцији.

Коначно, треба напоменути да се данас у пракси, због својих недостатака, ретко користи само *response-based* дестилација знања, већ се она комбинује са *feature-based* дестилацијом или другим комплементарним методама, што доприноси подизању тачности и робусности модела.

Литература

- [1] Hinton, G., Vinyals, O. & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*.
- [2] Gou, J., Yu, B., Maybank, S. J. & Tao, D. (2020). Knowledge distillation: A survey. *arXiv preprint arXiv:2006.05525*.
- [3] Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A. & Jégou, H. (2020). Training data-efficient image transformers & distillation through attention. *arXiv preprint arXiv:2012.12877*.
- [4] Romero, A., Ballas, N., Kahou, S. E., Chassang, A., Gatta, C. & Bengio, Y. (2014). FitNets: Hints for thin deep nets. *arXiv preprint arXiv:1412.6550*.
- [5] Park, W., Kim, D., Lu, Y. & Cho, M. (2019). Relational knowledge distillation. *arXiv preprint arXiv:1904.05068*.
- [6] Xu, G., Liu, Z., Li, X. & Loy, C. C. (2020). Knowledge distillation meets self-supervision. *arXiv preprint arXiv:2006.07114*.
- [7] Cheng, Y., Wang, D., Zhou, P. & Zhang, T. (2018). Model compression and acceleration for deep neural networks: The principles, progress, and challenges. *IEEE Signal Proc Mag* 35(1): 126–136.
- [8] Wu, J., Leng, C., Wang, Y., Hu, Q. & Cheng, J. (2016). Quantized convolutional neural networks for mobile devices. In: *CVPR*.
- [9] Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.